



Slide 1 — Introduction (20 à 30 s)



À dire

Bonjour. Aujourd'hui, je vais vous présenter le projet que j'ai réalisé dans le cadre de ma formation Data Engineer. L'objectif était de concevoir une plateforme permettant de collecter, traiter et valoriser des données sportives afin de répondre à un besoin métier exprimé par les ressources humaines.

Développer

- Projet OpenClassrooms
- Plateforme de traitement de données
- Vision de bout en bout
- Démonstration à la fin

Transition

Avant de présenter la solution, je vais d'abord revenir sur le contexte du projet.



Slide 2 — Contexte (45 s)



À dire

Le projet débute avec un besoin exprimé par Juliette, responsable des ressources humaines. Elle souhaite mettre en place un programme de bien-être afin d'encourager l'activité physique des collaborateurs. Pour piloter cette initiative, elle a besoin d'une plateforme capable de centraliser toutes les activités sportives.

Développer

Grâce à cette plateforme elle souhaite :

- suivre la participation

- calculer automatiquement les primes
- disposer d'indicateurs RH fiables
- recevoir une notification lorsqu'une nouvelle activité est réalisée

Petite conclusion

L'objectif n'est donc pas simplement de stocker des données, mais d'automatiser tout le processus de suivi des activités sportives.

Transition

Pour répondre à ce besoin, plusieurs objectifs ont été définis.



Slide 3 – Objectifs (45 secondes)



À dire

Pour répondre au besoin métier, j'ai organisé le projet autour de quatre objectifs principaux. Chacun correspond à une étape essentielle de la chaîne de traitement des données.

Développer

Premier objectif

Automatiser la collecte



API FastAPI

Deuxième

Garantir la qualité



Soda

Troisième

Produire des indicateurs

 PostgreSQL + Metabase

Quatrième

Automatiser le reporting

 Dashboard + Slack

Conclusion

L'idée était vraiment d'obtenir un pipeline entièrement automatisé, depuis la collecte jusqu'à la restitution.

Transition

Pour orchestrer toutes ces étapes, il fallait un outil capable de coordonner l'ensemble du pipeline.

Slide 4 – Orchestration : Pourquoi Kestra ? (1 min)

À dire

Une fois les objectifs définis, il fallait choisir un outil capable d'orchestrer l'ensemble des traitements. J'ai choisi Kestra, car il permet d'automatiser tout le pipeline et d'en assurer le suivi.

Développer

- Déclenche les différentes étapes dans le bon ordre.
- Évite les traitements manuels.
- Permet de suivre visuellement chaque exécution.
- Historique des workflows.

- Facilite le diagnostic en cas d'erreur.

👉 Montrer rapidement le workflow.

À ne pas oublier

Pourquoi Kestra ?

"Ce n'est pas uniquement un planificateur. C'est lui qui garantit que chaque étape est exécutée au bon moment et permet de superviser le pipeline."

Transition

Maintenant que l'orchestration est présentée, je vais montrer comment les différents composants communiquent entre eux.



Slide 5 – Architecture (1 min 30)



À dire

Cette diapositive présente l'architecture globale de la solution. J'ai fait le choix d'une architecture modulaire dans laquelle chaque composant possède une responsabilité bien définie.

Développer

👉 FastAPI

reçoit les activités envoyées par les utilisateurs.



👉 Redpanda

transforme ces activités en événements et les diffuse.



👉 Consumer Python

recupère les événements et les charge dans PostgreSQL.



👉 PostgreSQL

centralise les données et sert de source pour les traitements et le reporting.



👉 Soda

contrôle automatiquement la qualité des données avant leur exploitation.



👉 Metabase

restitue les données sous forme de tableaux de bord.



👉 Slack

envoie une notification lorsqu'une nouvelle activité est prise en compte.

Conclusion

Kestra orchestre l'ensemble de ces composants afin d'automatiser le pipeline de bout en bout.

À ne pas oublier

Ne pas entrer dans les détails techniques de chaque outil.

L'objectif est de montrer la logique du flux.

Transition

Je vais maintenant illustrer ce fonctionnement grâce à une démonstration.



Slide 6 – Démonstration (2 min 30)



À dire

L'objectif de cette démonstration est de montrer le fonctionnement complet du pipeline, depuis la création d'une activité jusqu'à sa visualisation dans le tableau de bord.

Étape 1

Swagger

Je commence par envoyer une nouvelle activité via l'API FastAPI.

Montrer :

POST

/live-activity

Exécuter.

Dire :

L'activité est validée puis publiée dans Redpanda.

Étape 2

Kestra

Je lance maintenant le workflow de consommation.

Pendant le chargement :

Le consumer récupère le message publié dans Redpanda et l'insère dans PostgreSQL.

Étape 3

Soda

Une fois les données chargées, Soda exécute automatiquement plusieurs contrôles qualité afin de vérifier leur cohérence.

Tu peux citer rapidement :

- valeurs obligatoires
 - cohérence des identifiants
 - intégrité des données
-

Étape 4

PostgreSQL

Montrer rapidement la nouvelle ligne.

On retrouve bien l'activité que je viens d'envoyer.

Étape 5

Metabase

Actualiser le dashboard.

Les indicateurs sont mis à jour automatiquement.

Étape 6

Slack

Enfin, une notification confirme qu'une nouvelle activité a été intégrée au système.

Conclusion

Cette démonstration montre le fonctionnement complet du pipeline de données.

Transition

Voyons maintenant comment ces données sont exploitées au travers du tableau de bord.



Slide 7 – Tableau de bord (1 min)



À dire

Les données collectées prennent tout leur intérêt lorsqu'elles sont valorisées sous forme d'indicateurs décisionnels. Le tableau de bord permet ainsi aux ressources humaines de suivre facilement l'activité sportive des collaborateurs.

Développer

Présenter uniquement les principaux KPI :

- nombre de collaborateurs
- nombre d'activités
- distance parcourue
- coût des primes

Puis deux graphiques :

- répartition des sports
- salariés les plus actifs

Conclusion

L'objectif est de fournir une vision claire et exploitable sans avoir à interroger directement la base de données.

Transition

Pour obtenir ce résultat, plusieurs choix techniques ont été réalisés.



Slide 8 – Choix techniques (1 min)



À dire

Chaque technologie a été choisie pour répondre à un besoin précis du projet. L'objectif n'était pas de multiplier les outils, mais d'utiliser la solution la plus adaptée à chaque étape du pipeline.

Développer

FastAPI

→ API légère et documentée

Redpanda

→ traitement événementiel

PostgreSQL

→ stockage fiable

Kestra

→ orchestration

Soda

→ qualité

Metabase

→ visualisation

Slack

→ notifications

Conclusion

Ces outils se complètent pour constituer une plateforme cohérente et automatisée.

Transition

Comme tout projet, celui-ci a également présenté plusieurs défis techniques.

Slide 9 – Difficultés rencontrées (1 min)

À dire

Au cours du projet, j'ai rencontré plusieurs difficultés techniques qui m'ont amenée à faire évoluer progressivement l'architecture de la solution.

Développer

Les principales difficultés :

- communication entre conteneurs Docker
- conflits de ports
- intégration de Soda
- gestion des volumes Docker

Puis ajouter ton exemple personnel :

Lors de la préparation de cette soutenance, j'ai également rencontré un problème de compatibilité entre un identifiant généré en 64 bits non signé et le type BIGINT de PostgreSQL. L'analyse des logs m'a permis d'identifier rapidement l'origine du problème et de corriger la génération de l'identifiant afin de sécuriser le pipeline.

Conclusion

Ces difficultés m'ont permis de renforcer la robustesse de la plateforme et d'améliorer ma démarche de diagnostic.

Transition

Pour conclure, je vais revenir sur les principaux résultats obtenus.



Slide 10 – Conclusion (45 secondes)



À dire

Ce projet m'a permis de mettre en œuvre l'ensemble des compétences attendues d'un Data Engineer : ingestion de données, orchestration, contrôle qualité, stockage et valorisation. La plateforme répond aujourd'hui au besoin initial tout en restant évolutive.

Développer

Aujourd'hui :

- pipeline automatisé
- données fiables
- reporting
- notifications

Demain :

- nouvelles sources
- objets connectés
- cloud
- authentification
- indicateurs prédictifs

Conclusion finale

Pour conclure, cette plateforme montre qu'il est possible d'automatiser l'ensemble du traitement des données, depuis leur collecte jusqu'à leur restitution, tout en garantissant leur qualité et leur exploitabilité. Je vous remercie pour votre attention et je suis disponible pour répondre à vos questions.